

文章编号

# 应用邻域点信息描述与匹配的点云配准

林森<sup>1</sup>, 张强<sup>2\*</sup>

(1 沈阳理工大学 自动化与电气工程学院, 辽宁 沈阳 110159;

2 辽宁工程技术大学 电子与信息工程学院, 辽宁 葫芦岛 125105)

**摘要:** 点云配准是现代制造业中逆向工程、机器视觉等技术的重要组成部分, 其效率和精度对获取的产品数据模型有重要影响。为提高3D物体点云配准的精度和效率, 提出一种应用邻域点信息描述与匹配的点云配准方法。首先, 在三个半径比例下根据点的曲率变化、测量角度和特征值性质提取特征点; 其次, 计算改进的法向量夹角、点密度和曲率值, 获取多尺度矩阵描述符; 然后, 为描述符建立k维树获取匹配关系, 并提出几何特征约束和刚性距离约束组合, 剔除错误点对, 实现粗配准; 最后, 通过k维树改进迭代最近点(Iterative Closest Point, ICP)算法完成精确配准。本文设计了实际物体点云配准和斯坦福模型模拟真实物体配准两组实验, 结果表明, 本文算法解决了经典ICP的局限性, 配准精度提高2~5个量级, 相较于其他算法, 实物点云配准中本文算法的配准精度至少提高29%, 效率可提高58%; 斯坦福模拟实验中, 本文算法的配准精度提高1%~99%, 配准耗时降低3%~94%。证明本文算法是一种有效的物体表面点云的配准方法, 可以提高配准精度和效率, 有较好的鲁棒性。

**关键词:** 逆向工程; 机器视觉; 点云配准; 邻域点信息; 迭代最近点

中图分类号: TP391.9

文献标识码: A

## Point cloud registration using neighborhood point information description and matching

Lin Sen<sup>1</sup>, Zhang Qiang<sup>2\*</sup>

(1 College of Automation and Electrical Engineering, Shenyang Ligong University, Shenyang, Liaoning 110159, China;

2 College of Electronic and Information Engineering, Liaoning University of Engineering and Technology, Huludao, Liaoning 125105, China))

**Abstract:** Point cloud registration is an important part of reverse engineering, machine vision and other technologies in modern manufacturing. Its efficiency and accuracy have an important impact on the acquisition of product data model. In order to improve the accuracy and efficiency of 3D object point cloud registration, a point cloud registration method using neighborhood point information description and matching is proposed. Firstly, under three radius ratios, feature points are extracted according to the change of curvature, measurement angle and eigenvalue property; Secondly, the improved normal vector angle, point density and curvature are calculated to obtain multi-scale matrix descriptor; Then, a k-dimensional tree is established for descriptors, and the matching relationship is preliminarily established. The combination of geometric feature constraint and rigid distance constraint is proposed to eliminate the wrong points; Finally, the k-tree improved iterative closest point (ICP) algorithm is used to complete the accurate registration. In this paper, two groups of experiments are designed, which are real object point cloud registration and Stanford model

simulation real object registration, The results show that the algorithm solves the limitations of the classical ICP, and improving the registration accuracy by 2-5 orders of magnitude; Compared with other algorithms, the registration accuracy of this algorithm is improved by at least 29%, and the efficiency is increased by 58%; In the Stanford database simulation experiment, the registration accuracy is improved by 1%-99%, and the registration time is reduced by 3%-94%. It is proved that this algorithm is an effective registration method of point cloud on object surface, which can improve the registration accuracy and efficiency, and has good robustness.

**Key words:** reverse engineering; machine vision; point cloud registration; neighborhood point information; iteration closest point

## 1 引言

随着三维(3D)激光扫描设备的飞速发展,点云已经成为表征三维世界的主要数据格式。在实际测量过程中,由于被测物体的几何形状和测量方法的限制,测量设备需要从不同角度对被测物体进行多次定位测量,每次测量只能捕获 3D 对象的部分点云,为了获得完整的 3D 对象,必须使用点云配准技术。点云配准就是把在不同视角下获取的多个 3D 点云数据,旋转平移到同一坐标系下。目前,3D 点云配准技术是逆向工程、数字医学图像、表面质量检测等领域的重要基础<sup>[1]</sup>。建立产品三维数据模型属于逆向工程的一个应用领域,配准结果好坏直接影响建模的正确性。

由于激光设备获取的 3D 物体点云部分区域重叠,且带有噪声和异常点,针对该类点云配准问题,一般分为粗配准和精确配准两个过程。粗配准就是估计两个点云之间的初始转换,分为深度学习配准方法和优化的配准方法,对于未知产品,若产品与训练数据存在较大的分布差异,深度学习配准方法性能会急剧下降,而优化的配准方法不需要训练数据,能更好的应用于产品建模<sup>[1]</sup>。基于优化的粗配准又分为三类:手动配准、用投票法则的配准和用局部特征的配准,其中局部特征的配准方法因效率高且能自动配准,所以应用更广泛。杨稳等人<sup>[2]</sup>提出层次优化的颅骨点云配准,该方法根据特征点的特征序列确定初始对应点对,能快速配准完整的颅骨点云,但针对更复杂的部分重叠物体点云,计算特征序列难以精准描述点的特征;Feng<sup>[3]</sup>等人提出一种基于局部特征描述符(Local Point Feature Histogram, LPFH)的粗配准,相较于常用描述符,其配准精度更高,但是粗配准框架并不剔除异常点,对于数据量大的复杂点云,整体效率低,并且难以完成配准;李新春等人<sup>[4]</sup>提出一种基于邻域特征点提取和匹配(Neighborhood Characteristic Point Extraction and Matching, NCCP)的点云配准,提高了精度,并解决了噪声干扰问题,但该方法在提取和匹配特征点时,两次使用最小二乘法计算对应点的曲率,耗费了大量时间。

粗配准结果为精确配准提供初始数据。对于精确

配准阶段,最经典、应用最广泛的方法是 Besl 等人<sup>[5]</sup>在 1992 年提出的 ICP 算法,基本原理是,最小化一个点云与另一个变换后点云之间的误差函数,迭代更新刚体变换,直到获得收敛为止,最后得到旋转平移矩阵。但是,ICP 算法很难找到需要大变换点云的旋转平移矩阵,从而陷入局部最小值,计算效率低,并且很难克服噪声。通过粗配准,可以解决 ICP 算法陷入局部最小值和鲁棒性差的问题,并且对于初始位置好的点云,还可以减少 ICP 的迭代次数来快速地完成配准两片点云,从而提高配准效率。针对 ICP 算法本身,也有各种改进。Choi 等人<sup>[6]</sup>提出用 k-d 树改进 ICP,通过加快搜索最近点的速度,提高了效率;Li 等人<sup>[7]</sup>给 ICP 迭代过程加入动态因子,在保证配准精度情况下,提高了 ICP 的收敛速度;王宾等人<sup>[8]</sup>在精确配准阶段提出基于双向距离比例的 ICP 算法,提高了配准精度;Zhang 等人<sup>[9]</sup>提出快速和鲁棒的 ICP 算法,基于 Welsch 函数改进误差度量,并使用具有 Anderson 加速功能的 Majorization-Minimization 算法将其最小化,提高了配准精度和效率,并且使配准框架具有更强的鲁棒性。

由于 3D 物体点云需将粗配准的匹配点对作为精确配准的输入数据,才能完成有效的点云配准<sup>[10]</sup>,因此粗配准结果的好坏,会直接影响精确配准的效率和精度,上述研究直接应用于部分重叠点云,配准效果不好,因此,针对部分重叠点云配准问题,提出应用邻域点信息描述与匹配的点云配准方法。首先,将曲率变化、测量角度和特征值性质指标组合,提取特征点;其次,改进法向量夹角,点密度和曲率,提出多尺度矩阵描述符;再次,提出用 k 维树初步建立匹配关系,并针对点的几何信息和欧氏距离,两次剔除错误匹配点对,完成粗配准;最后,用 k 维树改进 ICP 算法完成精确配准。该配准方法能完成 3D 对象表面点云配准,显著提高了配准的效率和精度,并在斯坦福点云数据库下,验证了算法的优势和鲁棒性。

## 2 点云的粗配准

以往的粗配准研究都从单个邻域点信息出发,进

行高维度的描述, 但是配准效率低。本文提出从点云数据的协方差矩阵出发, 结合点的多个邻域点几何信息, 提取特征点后, 进行低维度的描述。

## 2.1 特征点提取

提取特征点的目的是在点云数据中获取具有某些约束的点, 作为后续粗配准工作的输入点集。提取特征点的关键是具有旋转平移不变性, 使用单一的特征往往会导致配准计算量冗余、特征信息不完整<sup>[11]</sup>。因为曲率变化、测量角度和特征值性质的计算效率高、含有特征信息更多<sup>[12,13]</sup>, 所以将这三个特征组合并改进, 提出三尺度特征点(Curvature change, Measuring angle and Eigenvalue property, CME)。

点的曲率反映了曲面偏离平面的程度。对于给定的点  $p_i$ , 邻域的深度变化越剧烈, 以点  $p_i$  为中心的区域特征就越明显。如图 1(a)所示, 点 A、B 和 C 分别位于平滑、略有变化和急剧变化的区域, (b)-(d)表示不同半径曲面的切平面。对点 A, 在半径较小的情况下, 局部相邻表面近似为平面, 曲率近似为零。而点 B, C 的同心圆半径增加, 邻域表面会迅速变化, 且曲率增加。因此, 可以根据不同半径的曲率变化选择表示某些区域特征的点。

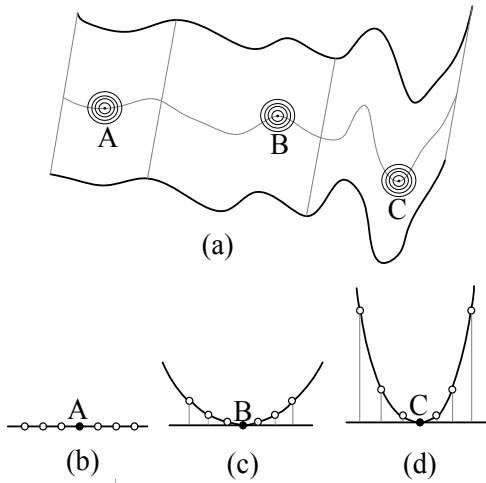


图 1 表面不同点的示例

Fig. 1 An example of different points in surface

设置查询点  $p_i$ , 在其半径  $r$  邻域内构造加权协方差矩阵:

$$\text{cov}(p_i) = \frac{\sum_{|p_i - p_j| < r} \omega_{ij} (p_i - p_j)(p_i - p_j)^T}{\sum_{|p_i - p_j| < r} \omega_{ij}}, \quad (1)$$

式中,  $p_j$  为邻域点,  $\omega_{ij} = \frac{1}{|p_i - p_j|}$  为权重。

求解公式(1)的特征值  $\lambda_{j1} \geq \lambda_{j2} \geq \lambda_{j3}$ , 曲率  $c_i$  计算如下:

$$c_i = \frac{\lambda_{j1}}{\lambda_{j1} + \lambda_{j2} + \lambda_{j3}}, \quad (2)$$

基于三个不同半径  $r_j (j=1,2,3)$  计算点  $p_i$  的三个不同曲率。对于弯曲表面,  $c_1, c_2, c_3$  大于零, 而对于平坦表面等于零。根据公式(3), 图 1(a)中的 A 点被删除, 而 B 和 C 点则被保留。

$$\frac{|c_1 - c_2|}{c_1 + c_2} \leq \varepsilon_c, \quad \frac{|c_2 - c_3|}{c_2 + c_3} \leq \varepsilon_c, \quad (3)$$

式中  $\varepsilon_c = 0.1$  为设定阈值<sup>[12]</sup>。

当物体的表面急剧变化时, 由于测量角度的问题, 相邻点的密度可能会减小, 并且点坐标误差可能会增加<sup>[14]</sup>, 这些点不能视为关键点, 例如 C 点, 用公式(4)剔除曲率和大于  $\varphi = 1.6$ <sup>[14]</sup>的不良点:

$$c_1 + c_2 < \varphi, c_2 + c_3 < \varphi, \quad (4)$$

通过求解协方差矩阵获得的特征值具有一定的几何意义<sup>[13]</sup>, 特征值的大小可以看作是椭球轴的长度, 特征矢量  $e_1, e_2, e_3$  可以看作是局部坐标系的轴, 如图 2 所示。椭球的形状是对邻域内点分布的抽象描述。如果邻点沿某个方向密集分布, 则该方向为椭球第一主方向。点分布稀疏的方向是第二主方向, 点分布极为稀疏是第三主方向。为了避免检测到沿主方向有相似伸展的特征点, 选择特征值变化量大于  $\rho = 1.25$ <sup>[13]</sup>的点:

$$\frac{\lambda_{11}}{\lambda_{12}} > \rho, \quad (5)$$

式中,  $\lambda_{11}, \lambda_{12}$  是第一个半径  $r_1$  对应协方差矩阵的特征值。




图 2 特征值和特征向量的几何意义

Fig. 2 Geometric significance of eigenvalue and eigenvectors

对于待配准的输入点云, 给定三个半径  $r_1, r_2, r_3$ , 取  $r_2 = 1.1r_1, r_3 = 1.2r_1$ , 满足公式(3)-(5)的点为 CME 特征点。

## 2.2 多尺度矩阵描述符

由于高维度的描述计算复杂度高,而单一的低维度描述特征识别度低,特征信息量少。因此,从点云表面的基本几何特征出发<sup>[3,4,15]</sup>, 选取计算复杂度最低的法向量、点密度和表面曲率进行改进,提出多尺度低维度的描述符。

设  $P$  是待配准的点云,它包含  $N$  个点  $\{p_1, p_2, \dots, p_N\}$ 。给定一个查询点  $p_i (i \in [1, N])$ , 其邻域是一个以  $p_i$  为中心, 半径为  $r$  的球体, 用  $p_{ij} = \{p_{ik} | k=1, 2, 3, \dots, j\}$  表示球体内  $p_i$  的相邻点, 其中  $k$  是  $p_i$  相邻点个数。设  $\bar{p}_i$  是  $p_{ik}$  质心, 在球体内建立协方差矩阵  $Cov_2(p_i)$ :

$$Cov_2(p_i) = \begin{bmatrix} p_{i1} - \bar{p}_i \\ \vdots \\ p_{ik} - \bar{p}_i \end{bmatrix}^T \cdot \begin{bmatrix} p_{i1} - \bar{p}_i \\ \vdots \\ p_{ik} - \bar{p}_i \end{bmatrix}, \quad (6)$$

$p_i$  的法向量  $\mathbf{n}_i$  可以用以下等式表示:

$$\mathbf{n}_i = \mathbf{V}_0, \lambda_{i0} \leq \lambda_{i1} \leq \lambda_{i2}, \quad (7)$$

式中,  $\lambda_{i0}, \lambda_{i1}, \lambda_{i2}$  是特征值,  $\mathbf{V}_0$  是  $\lambda_{i0}$  对应的特征向量。基于此, 提出三个尺度的几何描述:

(1)对于  $p_i$  和  $p_{ik}$ , 用两者法向量的  $\cos$  值作为第一个尺度, 用来描述点云表面区域的起伏变化, 如图 3 所示, 其中  $\theta$  是向量夹角。计算方法见公式(8)。




图 3 法向量夹角

Fig. 3 Normal vector included angle

$$F_1(p_{ik}) = (\mathbf{n}_i \cdot \mathbf{n}_{ik}) / (|\mathbf{n}_i| \cdot |\mathbf{n}_{ik}|), \quad (8)$$

式中,  $||$  表示向量的模,  $\mathbf{n}_i$  是查询点  $p_i$  的法向量,  $\mathbf{n}_{ik}$  是相邻点  $p_{ik}$  的法向量,  $F_1(p_{ik})$  是  $\mathbf{n}_i$  和  $\mathbf{n}_{ik}$  的  $\cos$  值。

$$\mathbf{V}_{\text{MSM}} = \sum_{i=1}^N \sum_{k=1}^j \left( \text{vote} \left( \left\lfloor \frac{25F_1(p_{ik})}{2} \right\rfloor \right) + \text{vote} \left( \left\lfloor \frac{15F_2(p_{ik})}{r} \right\rfloor + 25 \right) + \text{vote} \left( \left\lfloor \frac{20F_3(p_{ik})}{\sum F_3(p_{ik})} \right\rfloor + 40 \right) \right), \quad (11)$$

公式(11)中,  $N$  是特征点数量,  $\mathbf{V}_{\text{MSM}}$  是  $N \times 60$  维的矩阵,  $j$  为邻域点数量,  $\langle \cdot \rangle$  为四舍五入取整,  $||$  为绝对值,  $r$  为邻域半径,  $\overline{F_3(p_{ik})}$  为曲率的平均值。vote( $x$ ) 为定义的函数, 表示将第  $x$  个直方图记为 1。

## 2.3 获取匹配点对

为了提高特征匹配的识别度, 提出以下方法:

$F_1(p_{ik})$  的范围  $[-1, 1]$ , 将此范围划分为 25 个直方图, 并通过计算落入对应直方图中的数目来形成第一个尺度矩阵。

(2)文献[16]证明 3D 投影对噪声具有鲁棒性, 因此, 对于点  $p_i$ , 其法向量为  $\mathbf{n}_i$ , 将半径为  $r$  的球体内点集  $p_{ik}$  投影到垂直于  $\mathbf{n}_i$  的切面。投影点与  $p_i$  的欧氏距离作为第二个尺度, 用来描述点密度, 如图 4 所示, 图中  $L$  为垂直于  $\mathbf{n}_i$  的切面, 计算方法见公式(9):

$$F_2(p_{ik}) = \sqrt{\|p_i - p_{ik}\|^2 - (\mathbf{n}_i \cdot (p_i - p_{ik}))^2}, \quad (9)$$

式中,  $||$  表示欧氏距离,  $p_i$  为查询点,  $p_{ik}$  为邻域点,  $\mathbf{n}_i$  是  $p_i$  的法向量。最后, 将  $F_2(p_{ik})$  归一化并划分为 15 个直方图, 作为第二个尺度矩阵。




图 4 点密度特征图

Fig. 4 The illustration of point density feature

(3)对于点集  $P$  中的每个点  $p_i$ , 用表面曲率作为第三个尺度, 描述曲面在查询点处的弯曲程度, 计算方法见公式(10):

$$F_3(p_{ik}) = \frac{\lambda_{i2}}{\lambda_{i0} + \lambda_{i1} + \lambda_{i2}}, \quad (10)$$

式中,  $\lambda_{i0} \leq \lambda_{i1} \leq \lambda_{i2}$  是特征值。将  $F_3(p_{ik})$  归一化并划分为 20 个直方图, 作为第三个尺度矩阵。

法向量、点密度和表面曲率都具有旋转平移不变性, 描述的局部特征是唯一的<sup>[17]</sup>。因此, 可以将上文三个尺度矩阵组合, 形成特征点的多尺度矩阵描述符(Multi-scale matrix descriptor, MSM), 如公式(11)所示。

(1)设提取特征点的点集为  $P_a$  和  $Q_a$ , 两片点云的多尺度矩阵描述符为  $F(P_a)$ ,  $F(Q_a)$ 。建立  $k$  维树, 搜索  $F(P_a)$  和  $F(Q_a)$  欧氏距离最小的子向量, 把向量所对应的点, 初步建立起匹配关系, 记为:

$$K_1 = \{(h_i^1, h_i^2) | h_i^1 \in P_a, h_i^2 \in Q_a, i=1, 2, \dots, N_i\}, \quad (12)$$

式中,  $N_i$  为初步匹配点对数量。通过  $k$  维树初步建



立匹配关系,其替代了常用方法中需要遍历全部点过程,提高了效率,同时也替代了设定欧氏距离阈值获取匹配点对的方式,解决了因欧氏距离阈值设置不合理而导致删除正确匹配点对的问题<sup>[9]</sup>。

(2)对于点对集  $K_1$ ,  $h_i^1$  内任意点  $p_i$  对应的法向量夹角、点密度、曲率,分别为  $F_1(p_i)$ 、 $F_2(p_i)$ 、 $F_3(p_i)$ 。 $h_i^2$  内任意点  $q_i$  对应的法向量夹角、点密度、曲率,分别为  $F_1(q_i)$ 、 $F_2(q_i)$ 、 $F_3(q_i)$ 。满足公式(13)则认为对应关系正确,建立如公式(14)所示的匹配点对集  $K_2$ 。

$$\begin{cases} |F_1(p_j) - F_1(q_j)| / [F_1(p_j) + F_1(q_j)] \leq \sigma_1 \\ |F_2(p_j) - F_2(q_j)| / [F_2(p_j) + F_2(q_j)] \leq \sigma_2, (13) \\ |F_3(p_j) - F_3(q_j)| / [F_3(p_j) + F_3(q_j)] \leq \sigma_1 \end{cases}$$

式中,  $||$  为绝对值,  $\sigma_1 = \sigma_2 = \sigma_3 = 0.1$  为设定阈值<sup>[18]</sup>。

$$K_2 = \{(h_j^1, h_j^2) | h_j^1 \in P_a, h_j^2 \in Q_a, j = 1, 2, \dots, N_j\}, (14)$$

式中,  $N_j$  为匹配点对数量。

(3)使用刚性距离约束检验点对集  $K_2$ , 在  $K_2$  任选两个匹配点对  $(p_j, q_j)$ ,  $(p_k, q_k)$ , 根据文献[4]设定阈值  $\tau = 0.005$ , 若匹配点对不满足公式(15), 则从集合  $K_2$  中剔除, 直到遍历  $K_2$ , 得到精炼的匹配点对集  $K_3$ 。

$$\frac{\|p_j - p_k\| - \|q_j - q_k\|}{\|p_j - p_k\| + \|q_j - q_k\|} < \tau, (15)$$

式中,  $\| \cdot \|$  表示欧氏距离。

$$K_3 = \{(h_k^1, h_k^2) | h_k^1 \in P_a, h_k^2 \in Q_a, k = 1, 2, \dots, N_k\}, (16)$$

式中,  $N_k$  为经过两种配对参数精炼后获得的正确匹配点对的数量。

最后对匹配点对集  $K_3$  用单位四元数算法<sup>[18]</sup>, 获取旋转矩阵  $R_a$  和平移向量  $T_a$ 。

### 3 精确配准

对于源点云  $Q$ , 根据初始配准获取的旋转矩阵  $R_a$  和平移向量  $T_a$ , 用公式(17)变换得到  $Q'$ , 将  $P$  和  $Q'$  作为输入点云。

$$Q' = R_a \cdot Q + T_a, (17)$$

为了得到精度更高的配准结果, 本文使用  $k$  维树 ICP(K-dimensional tree Iterative Closest Point, KICP) 进行精确配准, 具体步骤如下:

(1)输入待配准的点云  $P$  和  $Q'$ , 设定终止阈值  $\eta$ <sup>[5]</sup> 和最大迭代次数;

(2)对于  $Q'$  中一点, 用  $k$  维树在  $P$  中寻找欧氏距

离最近的对应点, 得到对应点对, 直到遍历  $Q'$ ;

(3)用 SVD 法计算对应点对的旋转矩阵  $R_k$  和平移向量  $T_k$ , 然后计算公式(18)的目标函数;

$$E_k = \frac{1}{n} \sum_{i=1}^n \|R_k \cdot p_i + T_k - q_i\|^2, (18)$$

(4)将步骤(3)的旋转矩阵  $R_k$  和平移向量  $T_k$  应用于  $Q'$ , 计算  $Q'_{k+1} = R_k \cdot Q' + T_k$ , 用  $Q'_{k+1}$  替代  $Q'$ ;

(5)计算步骤(3)中相邻两次目标函数的变化, 若  $E_{k+1} - E_k < \eta$  或达到设定的最大迭代次数时, 则终止迭代, 否则转向步骤(2)。

本文的配准算法总流程可归结为图 5 所示。

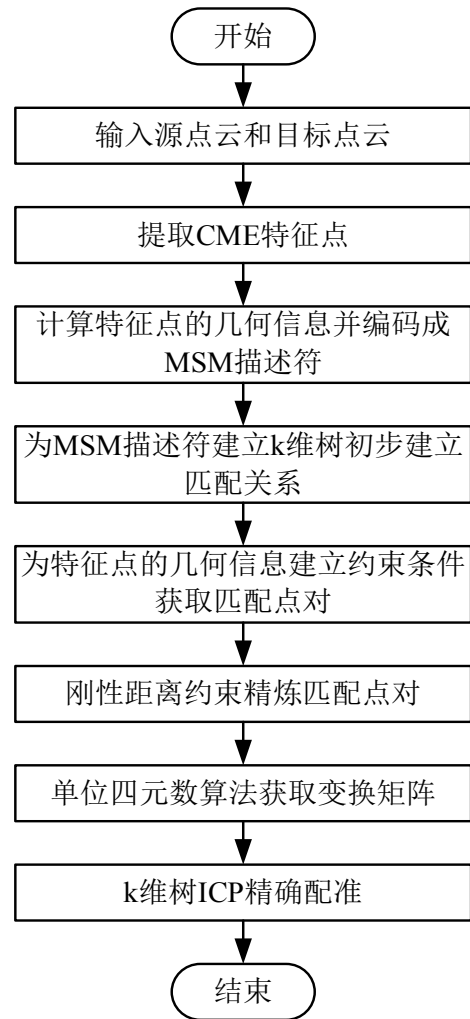


图 5 配准流程

Fig. 5 registration process

## 4 实验结果及分析

本部分实验均在配置为 Intel core i5 2.3GHz CPU、8GB 内存的计算机上完成。

### 4.1 特征点提取结果的比较

为了验证提取 CME 特征点的必要性, 采用斯坦

福大学的 Bunny(35947)和 Dragon(56053)点云模型, 将 CME 约束提取特征点与曲率变化(Curvature change, CC)、测量角度(Measuring angle, MA)、特征值性质(Eigenvalue property, EP)以及两两组合的方法比较, 分别讨论 7 类提取方法获取的特征点数量、对粗配准效率和精度的影响, 如图 6 所示。人为选定点云第一个点为初始查询点。

由图 6(a)可以看出, 使用单一特征提取的特征点数量多于两个特征组合, 而 CME 约束提取特征点

量最少, 证明特征约束越多, 提取特征点数量越少。由图 6(b)可知, 特征点数量越多, 在计算描述符和获取匹配点对时越耗时, CME 特征点数量最少, 所以粗配准效率最高。由图 6(c)可知, 由于使用单一特征提取的点集内存在大量异常点, 故配准误差大, 精度低; 而使用两个特征组合配准精度明显提升; CME 特征点提取效果最好, 因此粗配准误差最小。综上所述, 使用 CME 特征点会让两组待配准的点云有更好的初始位置, 且配准效率最高。




图 6 特征点粗配准结果对比

Fig. 6 Influence of feature points on initial registration result

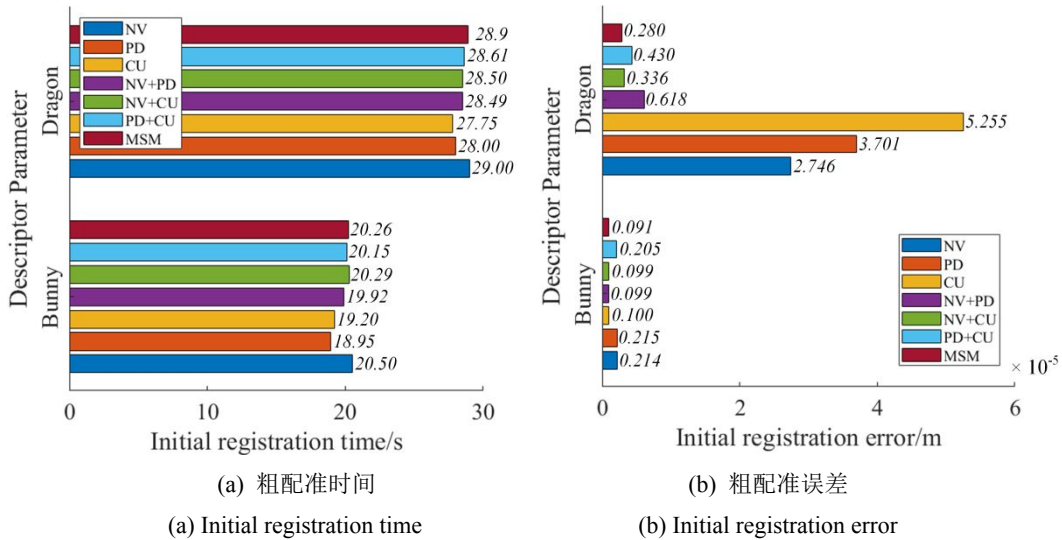


图 7 描述符对比实验

Fig. 7 Descriptor comparison experiment

#### 4.2 描述符描述结果的比较

为了证明构造多尺度矩阵描述符(MSM)的必要性, 将 MSM 与法向量(Normal vector, NV)矩阵、点密度(Point density, PD)矩阵、曲率(Curvature, CU)矩阵以及两两组合构成的描述符进行对比, 如图 7 所示, 并讨论 7 种描述符计算效率以及对粗配准结果的影

响。

由图 7(a)可以看出, 相同模型下 7 种描述粗配准时间最大与最小相差都约 1s, 证明描述符的三个子尺度矩阵计算效率都很高, 提出的 MSM 描述符时间计算复杂度低。由图 7(b)可知, 对于简单的 Bunny 模型, 使用 MSM 描述符精度虽然最小, 但相比于其他描述符, 配准精度提升不大, 所以提出的三个子尺

度矩阵及其组合的描述符, 都能完成简单点云模型的配准, 证明了三个子特征的有效性。而较复杂的 Dragon 模型配准, 使用一个子尺度矩阵描述特征点描述性有限, 所以粗配准误差最高; 使用两个子尺度矩阵粗配准精度明显提升; 而 MSM 粗配准精度最高, 证明 MSM 的描述性最强, 获取的匹配点对几何特征最接近。

#### 4.3 物体表面点云配准比较

本节使用的物体点云是 Leica P50 扫描仪在实际环境不同视角下对实验室某机器人(Robot)进行扫描获取的点云数据<sup>[19]</sup>, 点数为 296356、269132。评价指标为配准总耗时和配准误差( $\zeta_{\text{RMSE}}$ ),  $\zeta_{\text{RMSE}}$  定义<sup>[9]</sup>

见公式(18)。

$$\zeta_{\text{RMSE}} = \sqrt{\frac{1}{N_p} \sum_{i=1}^{N_p} \|Rp_i + T - q_j\|}, \quad (18)$$

为验证提出的配准方法有更高的配准效率和精度, 将本文的配准算法和经典 ICP 算法、基于 LPPH 的 KICP 算法<sup>[3]</sup>、基于 NCCP 的双向 k 维树 ICP(Bidirectional k-d tree ICP, BKICP)算法<sup>[4]</sup>、基于半正定的随机算法(Semidefinite-Based Randomized Approach, SDRSAC)<sup>[20]</sup>、采样一致性无损检测(Sampling Consensus and Nondestructive Testing, SAC-IA NDT)算法<sup>[21]</sup>做对比, 配准结果如图 8, 配准数据见表 1。




图 8 Robot 配准效果

Fig. 8 Registration result of Robot

图 8 整体来看, 经典 ICP 无法完成有效的点云配准, SAC-IA NDT 出现明显的错配, 其他 4 种配准算法都能完成较好的配准。观察左臂、胸口屏幕和底座三处细节进行对比, LPPH-KICP 和 NCCP-BKICP 在左臂和胸口屏幕按钮处配准有微小的偏差, 在底座

拼接处有明显的错位; SDRSAC 在左臂处有明显的错位, 胸口屏幕按钮处有微小偏差, 而本文算法在这三个部分的配准线条更加流畅, 配准效果最好。由于 Robot 点云数量大且重叠率低, 即使配准框架的计算复杂度低, 配准也会非常耗时。通过表 1 定量分析,



本文算法比经典 ICP 的配准精度高 2 个量级。与 LPFH-KICP 算法相比, 本文算法配准效率提高了 40%, 配准精度提高了 35%; 与 NCCP-BKICP 算法相比, 本文算法配准效率提高了 51%, 配准精度提高了 40%。与 SDRSAC 算法相比, 本文算法配准效率提高了 58%, 配准精度提高了 29%。与 SAC-IA NDT 算法相比, 本文算法配准效率提高了 54%, 配准精度提高 2 个量级。所以, 本文算法在配准效率和精度上有较大优势, 证明本文三重约束提取特征点和多特征低维度描述符组合, 又两次剔除错误匹配点对的方法, 使配准效果更好, 效率更高。

综合上述实验, 本文算法可以完成具有较大初始位置差异和部分区域重叠的实际物体表面点云的配准, 并且有较高的配准效率和精度。

表 1 Robot 模型配准数据  
Tab. 1 Registration data of Robot model

Algorithm	Time/s	$\xi_{\text{RMSE}}/\text{m}$
Classic ICP	120.541	$1.997 \times 10^{-2}$
LPFH-KICP	251.965	$1.718 \times 10^{-4}$
NCCP-BKICP	313.383	$1.860 \times 10^{-4}$
<u>SDRSAC</u>	<u>364.356</u>	<u><math>1.579 \times 10^{-4}</math></u>
<u>SAC-IA NDT</u>	<u>328.384</u>	<u><math>1.511 \times 10^{-2}</math></u>
<b>Proposed</b>	<b>151.935</b>	<b><math>1.115 \times 10^{-4}</math></b>

#### 4.4 数据库模型点云配准实验

为了验证本文算法在其他点云模型上也具有较高的配准效率和精度, 采用斯坦福大学模型设置两组实验。第一组实验考虑实际采集的点云有残缺, 源点云为 Bunny(35947)模型, 目标点云为源点云在三维空间做( $\mathbf{R}_e, \mathbf{t}_e$ )的大幅度旋转平移变换, 对目标点云随机剔除 5%, 10%, 15%, 20%的点数。第二组实验考虑实际采集点云数据带有噪声, 源点云为 Dragon(52368)模型, 目标点云为源点云做( $\mathbf{R}_e, \mathbf{t}_e$ )变换, 对目标点云分别加入  $0.1\bar{r}$ 、 $0.2\bar{r}$ 、 $0.3\bar{r}$ 、 $0.5\bar{r}$  的高斯白噪声, 其中  $\bar{r}$  为平均密度。配准耗时是粗、精配准总时间, 配准精度使用变换矩阵相对误差<sup>[8]</sup>, 如公式(19)所示。Bunny 模型配准结果图和配准数据见图 9 和表 2, Dragon 模型配准结果图和配准数据见图 10 和表 3。

$$\begin{cases} \xi_R = \|\mathbf{R}_k - \mathbf{R}_e\|_F \\ \xi_t = \|\mathbf{t}_k - \mathbf{t}_e\|_2 \end{cases}, \quad (19)$$

式中,  $\xi_R$  是相对旋转误差,  $\xi_t$  是相对平移误差,  $(\mathbf{R}_k, \mathbf{t}_k)$  是精确配准求解的旋转平移矩阵,  $(\mathbf{R}_e, \mathbf{t}_e)$  是

设定的旋转平移矩阵,  $\|\cdot\|_F$  是  $F$  范数,  $\|\cdot\|_2$  是 2 范数。

由于斯坦福模型的结构相对简单, 点云表面多处特征相似, 若提取的特征点代表性不强, 描述符描述性差, 会导致错误匹配点对急剧增加, 从而影响精确配准的结果和效率, 并且对于数据量小的点云, 粗配准提取特征点的耗时较少, 此时描述符的耗时会直接影响配准效率。

由图 9 可以看出, 对于不同数据残缺(剔除点云比例)的 Bunny 模型点云, 经典 ICP 无法完成有效的配准, 其他算法配准效果良好。根据表 2 定量分析 6 种算法的相对平移误差相差不大。相比于经典 ICP 本文算法的相对旋转误差降低 3~4 个量级。与 LPFH-KICP 算法相比, 本文算法的配准耗时降低了 26%~36%, 相对旋转误差减少了 8%~66%。与 NCCP-BKICP 算法相比, 本文算法的配准耗时降低 55%~64%; 在相对旋转误差上, 剔除 15%~20%点云时, 本文算法减少 43%~66%。与 SDRSAC 算法相比, 本文算法的配准耗时降低 60%~64%, 相对旋转误差降低 82%~99%。与 SAC-IA NDT 算法相比, 本文算法的配准耗时降低 92%~94%, 相对旋转误差降低 89%~99%。可以看出, 本文算法在配准效率和精度上均有优势, 并且, 随着剔除点云比例的增加, 本文算法能保持较稳定的配准精度, 而 LPFH-KICP 和 NCCP-BKICP 的相对旋转误差不断变大, SDRSAC 和 SAC-IA NDT 的相对旋转误差起伏较大,由此可以证明, 本文算法有更强的鲁棒性。

根据图 10 和表 3, 对带有不同噪声的 Dragon 点云, 经典 ICP 仍无法完成有效的配准, 配准精度较本文差 4~5 个量级。且 6 种算法相对平移误差相同。相比于 LPFH-KICP 算法, 本文算法的配准耗时减少了 3%~18%, 相对旋转误差减少了 1%~33%; 相比于 NCCP-BKICP 算法, 本文算法的配准耗时减少 17%~30%, 相对旋转误差减少了 1%~19%。相比于 SDRSAC 算法, 本文算法的配准耗时降低 16%~53%, 相对旋转误差降低 14%~77%。相比于 SAC-IA NDT 算法相比, 本文算法的配准耗时降低 83%~88%, 相对旋转误差降低 2~3 个量级。由此可以证明, 对于带噪声的点云, 本文算法的配准效率和精度仍有优势, 这是由于本文多重几何特征约束的粗配准方法, 在噪声环境下有更好的鲁棒性, 能给精确配准提供更好的初始点云。

通过对斯坦福点云模型的配准结果分析, 可以确定在带有数据缺失和噪声环境下, 对于不同的点云模型, 本文算法仍有较高的配准效率和精度, 并且有较好的鲁棒性。



表 2 Bunny 模型配准数据  
Tab. 2 Registration data of Bunny model

		Eliminate point cloud ratio (number of point clouds)			
		5%(34146)	10%(32352)	15%(30554)	20%(28757)
$\zeta_R$	Time /s				
	Classic ICP	1.987	1.687	1.745	1.700
	LPFH-KICP	22.079	22.225	21.747	21.291
	NCCP-BKICP	36.873	35.997	39.381	37.855
	<a href="#">SDRSAC</a>	<a href="#">42.014</a>	<a href="#">40.848</a>	<a href="#">38.958</a>	<a href="#">38.841</a>
	<a href="#">SAC-IA NDT</a>	<a href="#">195.080</a>	<a href="#">204.044</a>	<a href="#">250.181</a>	<a href="#">201.860</a>
	<b>Proposed</b>	<b>15.803</b>	<b>16.356</b>	<b>14.884</b>	<b>13.716</b>
	Classic ICP	1.497	1.4969	1.4935	1.495
	LPFH-KICP	$3.731 \times 10^{-4}$	$1.002 \times 10^{-3}$	$1.414 \times 10^{-3}$	$2.187 \times 10^{-3}$
	NCCP-BKICP	$1.694 \times 10^{-4}$	$9.276 \times 10^{-4}$	$1.541 \times 10^{-3}$	$2.144 \times 10^{-3}$
$\zeta_I$	<a href="#">SDRSAC</a>	<a href="#">3.730 <math>\times 10^{-2}</math></a>	<a href="#">5.108 <math>\times 10^{-3}</math></a>	<a href="#">7.101 <math>\times 10^{-2}</math></a>	<a href="#">3.676 <math>\times 10^{-2}</math></a>
	<a href="#">SAC-IA NDT</a>	<a href="#">2.101 <math>\times 10^{-2}</math></a>	<a href="#">8.165 <math>\times 10^{-3}</math></a>	<a href="#">2.326 <math>\times 10^{-2}</math></a>	<a href="#">2.723 <math>\times 10^{-2}</math></a>
	<b>Proposed</b>	<b>1.665 <math>\times 10^{-4}</math></b>	<b>9.188 <math>\times 10^{-4}</math></b>	<b>8.653 <math>\times 10^{-4}</math></b>	<b>7.262 <math>\times 10^{-4}</math></b>
	Classic ICP	0.274	0.274	0.274	0.274
	LPFH-KICP	0.274	0.273	0.273	0.273
	NCCP-BKICP	0.273	0.273	0.273	0.273
	<a href="#">SDRSAC</a>	<a href="#">0.274</a>	<a href="#">0.273</a>	<a href="#">0.276</a>	<a href="#">0.276</a>
	<a href="#">SAC-IA NDT</a>	<a href="#">0.274</a>	<a href="#">0.273</a>	<a href="#">0.273</a>	<a href="#">0.274</a>
	<b>Proposed</b>	<b>0.273</b>	<b>0.273</b>	<b>0.273</b>	<b>0.273</b>


Eliminate 10% of point cloud



Eliminate 10% of point cloud



Eliminate 15% of point cloud



Eliminate 20% of point cloud

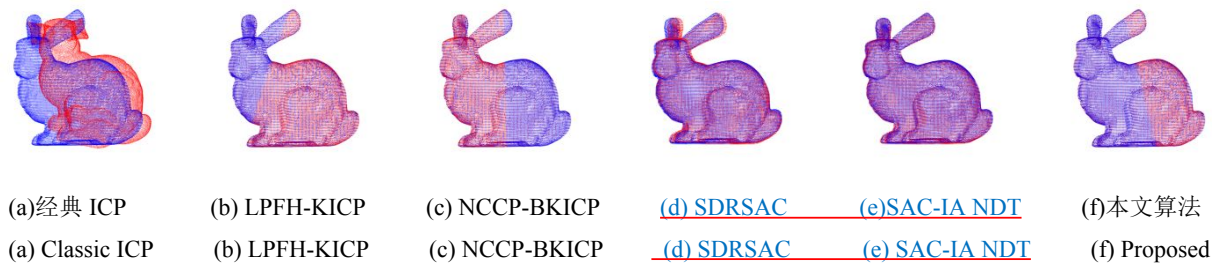


图 9 Bunny 配准效果


Fig. 9 Registration result of Bunny

表 3 Dragon 模型配准数据

Tab. 3 Registration data of Dragon model

		Gaussian white noise ratio			
		$0.1\bar{r}$	$0.2\bar{r}$	$0.3\bar{r}$	$0.5\bar{r}$
Time/s	Classic ICP	4.644	4.672	4.726	5.546
	LPFH-KICP	44.752	45.817	49.556	53.374
	NCCP-BKICP	52.883	54.181	60.265	62.436
	<u>SDRSAC</u>	<u>77.665</u>	<u>54.672</u>	<u>59.745</u>	<u>67.113</u>
	<u>SAC-IA NDT</u>	<u>300.737</u>	<u>301.982</u>	<u>307.681</u>	<u>305.503</u>
	<b>Proposed</b>	<b>36.781</b>	<b>37.824</b>	<b>44.691</b>	<b>51.895</b>
$\zeta_R$	Classic ICP	1.787	1.788	1.787	1.789
	LPFH-KICP	$1.311 \times 10^{-5}$	$4.821 \times 10^{-5}$	$3.149 \times 10^{-5}$	$1.173 \times 10^{-4}$
	NCCP-BKICP	$1.302 \times 10^{-5}$	$4.549 \times 10^{-5}$	$2.544 \times 10^{-5}$	$1.392 \times 10^{-4}$
	<u>SDRSAC</u>	<u><math>1.956 \times 10^{-5}</math></u>	<u><math>4.691 \times 10^{-5}</math></u>	<u><math>5.474 \times 10^{-5}</math></u>	<u><math>1.591 \times 10^{-4}</math></u>
	<u>SAC-IA NDT</u>	<u><math>1.765 \times 10^{-2}</math></u>	<u><math>1.737 \times 10^{-2}</math></u>	<u><math>1.266 \times 10^{-2}</math></u>	<u><math>3.497 \times 10^{-2}</math></u>
	<b>Proposed</b>	<b><math>1.301 \times 10^{-5}</math></b>	<b><math>4.004 \times 10^{-5}</math></b>	<b><math>2.122 \times 10^{-5}</math></b>	<b><math>1.128 \times 10^{-4}</math></b>
$\zeta_t$	Classic ICP	0.954	0.954	0.954	0.954
	LPFH-KICP	0.273	0.273	0.273	0.273
	NCCP-BKICP	0.273	0.273	0.273	0.273
	<u>SDRSAC</u>	<u>0.273</u>	<u>0.273</u>	<u>0.273</u>	<u>0.273</u>
	<u>SAC-IA NDT</u>	<u>0.273</u>	<u>0.273</u>	<u>0.273</u>	<u>0.273</u>
	<b>Proposed</b>	<b>0.273</b>	<b>0.273</b>	<b>0.273</b>	<b>0.273</b>

$0.1\bar{r}$  Gaussian white noise



$0.2\bar{r}$  Gaussian white noise



$0.3\bar{r}$  Gaussian white noise

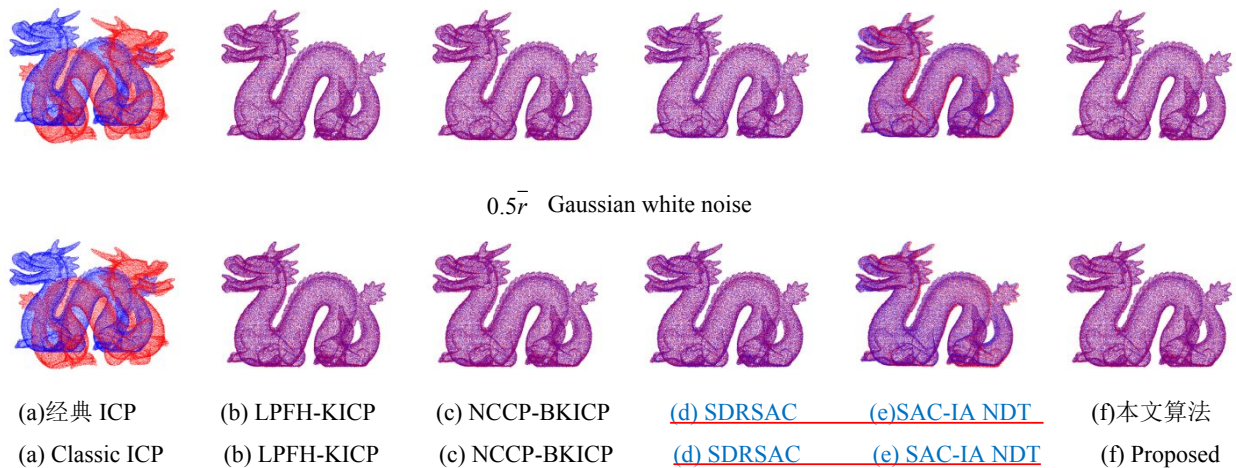


图 10 Dragon 配准效果

Fig. 10 Registration result of Dragon

## 5 结论

为了提高点云配准技术的配准精度和效率, 对 3D 点云数据局部坐标的几何信息深入分析, 本文提出了应用邻域点信息描述与匹配的点云配准方法。首先, 针对点云表面深度变化, 提取特征点; 其次, 改进法向量夹角, 点密度和曲率三个几何特征, 提出了一个多尺度矩阵描述符; 再次, 提出用 k 维树初步建立匹配关系, 并结合几个特征和刚性距离约束, 剔除错误匹配点对, 实现粗配准, 最后, 在粗配准基础上, 用 k 维树 ICP 算法完成精确配准。对于实物点云配

准, 本文算法比经典 ICP 配准精度提高 2 个量级, 相比于其他算法, 配准精度、效率至少提升 29%、54%, 证明本文算法有较高的配准精度和效率。算法的优势还体现在: 一是对于不同数据缺失和带有不同噪声的点云, 精度和效率优势不受影响; 二是在模型数据量较大时, 配准效率优势更加明显。因此本文算法可以应用于 3D 物体表面点云的配准中。进一步优化配准方法, 并将本文算法应用于其他环境中, 如生物医学中颅骨、膝盖等模型的配准问题, 是下一步研究的方向。

## 参考文献:

- [1] LIN X, ZHOU Y, LIN C. Study on 3D Data Mosaic Method of Point Cloud Data in Reverse Engineering[C]//2021 Asia-Pacific Conference on Communications Technology and Computer Science (ACCTCS). IEEE, 2021: 143-147.
- [2] 杨稳, 周明全, 耿国华, 等. 层次优化的颅骨点云配准[J]. 光学精密工程, 2019, 27(12): 2730-2739.
- [3] YANG W, ZHOU M D, GENG G H, *et al.* Hierarchical optimization of skull point cloud registration[J]. Optics and Precision Engineering, 2019, 27(12): 2730-2739.
- [4] FENG X, TAN T, YUAN Y, *et al.* Aligning Point Clouds with an Effective Local Feature Descriptor[M]//Cyberspace Data and Intelligence, and Cyber-Living, Syndrome, and Health. Springer, Singapore, 2019: 241-255.
- [5] 李新春, 闫振宇, 林森, 等. 基于邻域特征点提取和匹配的点云配准[J]. 光子学报, 2020, 49(4): 255-265.
- [6] LI X CH, YAN ZH Y, LIN S, *et al.* Point Cloud Registration Based on Neighborhood Characteristic Point Extraction and Matching[J]. Acta Photonica Sinica, 2020, 49(4): 255-265.
- [7] BESL P J, MCKAY IV N D. Sensor Fusion IV: Control Paradigms and Data Structures[J]. International Society for Optics and Photonics, 1992, 1611: 586-607.
- [8] CHOI W S, KIM Y S, OH S Y, *et al.* Fast iterative closest point framework for 3D LIDAR data in intelligent vehicle[C]//2012 IEEE Intelligent Vehicles Symposium. IEEE, 2012: 1029-1034.
- [9] LI W, SONG P. A modified ICP algorithm based on dynamic adjustment factor for registration of point cloud and CAD model[J]. Pattern Recognition Letters, 2015, 65: 88-94.
- [10] 王宾, 刘林, 侯榆青, 等. 应用改进迭代最近点方法的三维心脏点云配准[J]. 光学精密工程, 2020, 28(2): 474-484.
- [11] WANG B, LIU L, HOU Y Q, *et al.* Three-dimensional cardiac point cloud registration by improved iterative closest point method[J]. Optics and Precision Engineering, 2020, 28(2): 474-484.
- [12] ZHANG J, YAO Y, DENG B. Fast and Robust Iterative Closest Point[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021.
- [13] 张琮毅, 魏子庄, 徐昊文, 等. 尺度可变的快速全局点云配准方法[J]. 计算机学报, 2019, 42(09): 1939-1952.



- ZHANG C Y, WEI Z ZH, XU H W, *et al.* Scale Variable Fast Global Point Cloud Registration[J]. Chinese Journal of Computers, 2019, 42(09): 1939-1952.
- [11] GRUEN A, AKCA D. Least squares 3D surface and curve matching[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2005, 59(3): 151-174.
- [12] LU B, WANG Y. Matching Algorithm of 3D Point Clouds Based on Multiscale Features and Covariance Matrix Descriptors[J]. IEEE Access, 2019, 7: 137570-137582.
- [13] [LU J, WANG W, SHAO H, \*et al.\* Point Cloud Registration Algorithm Fusing of Super 4PCS and ICP Based on the Key Points\[C\]//2019 Chinese Control Conference \(CCC\). IEEE, 2019: 4439-4444.](#)
- [14] [LU J, PENG Z, SU H, \*et al.\* Registration algorithm of point clouds based on multiscale normal features\[J\]. Journal of Electronic Imaging, 2015, 24\(1\): 013037.](#)
- [15] [LAGUE D, BRODU N, LEROUX J. Accurate 3D comparison of complex topography with terrestrial laser scanner: Application to the Rangitikei canyon \(N-Z\) \[J\]. ISPRS journal of photogrammetry and remote sensing, 2013, 82: 10-26.](#)
- [16] [RUSU R B, MARTON Z C, BLODOW N, \*et al.\* Towards 3D point cloud based object maps for household environments\[J\]. Robotics and Autonomous Systems, 2008, 56\(11\): 927-941.](#)
- [17] [FENG G X, BIAO D, WANG H, \*et al.\* A Local Feature Descriptor Based on Rotational Volume for Pairwise Registration of Point Clouds\[J\]. IEEE Access, 2020, 8: 100120-100134.](#)
- [18] [黄源,达飞鹏,陶海骅. 一种基于特征提取的点云自动配准算法\[J\]. 中国激光, 2015, 42\(3\): 250-256.](#)  
[HUANG Y, DA F P, TAO H J. An Automatic Registration Algorithm for Point Cloud Based on Feature Extraction\[J\]. Chinese Journal of Lasers, 2015, 42\(3\): 250-256.](#)
- [19] [李宇翔, 郭际明, 潘尚毅, 等. 一种基于 ISS-SHOT 特征的点云配准算法\[J\]. 测绘通报, 2020, 04: 21-26.](#)  
[LI Y X, GUO J M, PAN SH Y, \*et al.\* A point cloud registration algorithm based on ISS-SHOT features\[J\]. Bulletin of Surveying and Mapping, 2020, 0\(4\): 21-26.](#)
- [20] [LE H M, DO T T, HOANG T, \*et al.\* SDRSAC: Semidefinite-based randomized approach for robust point cloud registration without correspondences \[C\]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 124-133.](#)
- [21] [荆路, 武斌, 李先帅. 基于 SAC-IA 和 NDT 融合的点云配准方法\[J\]. 大地测量与地球动力学, 2021, 41\(04\): 378-381.](#)  
[JING L, WU B, LI X S. Point cloud registration method based on the fusion of SAC-IA and NDT\[J\]. Journal of Geodesy and Geodynamics, 2021, 41\(04\): 378-381.](#)

**作者简介:** 林森(1980-), 男, 辽宁沈阳人, 博士后, 硕士生导师, 2003 年和 2006 年于辽宁工程技术大学分别获得学士、硕士学位, 2013 年在沈阳工业大学获得博士学位, 2019 年于中国科学院沈阳自动化研究所博士后出站, 现为沈阳理工大学副教授, 主要从事图像处理与模式识别方面的研究。E-mail: lin\_sen6@126.com



**通讯作者:** 张强 (1996-), 男, 河北唐山人, 硕士研究生在读, 主要从事机器视觉方面的研究。E-mail: 1351511023@qq.com



### 创新点说明:

对于 3D 物体表面点云, 由于扫描设备视野的限制, 需要从不同角度对 3D 物体进行多次定位扫描, 每次扫描只能捕获 3D 对象的部分点云, 此时对部分点云建立良好的匹配点对关系, 才能有效地完成点云配准。基于此, 为了提高配准效率和精度, 本文提出以下创新:

#### 1. 提出一种新的提取特征点方法(CME)。

在三个不同的半径比例下, 考虑查询点的曲率变化、测量角度和协方差矩阵特征值变化, 提出三种约

束提取特征点。实验首先证明进行三次半径搜索的粗配准耗时最少, 因此本文提取特征点方法不会降低整体计算效率, 其次证明三种约束与单个约束、三种约束两两组合相比, 粗配准效果最好。

## 2. 提出一种低维度多特征的描述符: 多尺度矩阵描述符(MSM)

法向量夹角的  $\cos$  值作为第一个尺度, 用来描述点云表面区域的起伏变化; 将球体内点集  $p_{ik}$  投影到垂直于查询点法向量的切面, 投影点与  $p_i$  的欧氏距离作为第二个尺度, 用来描述点密度; 用曲率作为第三个尺度, 描述曲面在查询点处的弯曲程度。对三个尺度进行编码, 得到 MSM 描述符。进行消融实验证明, MSM 描述符与单个尺度、三个尺度两两组合相比, 计算效率相差约 1 秒, 可以证明 MSM 描述符三个子矩阵计算效率高; 使用 MSM 粗配准精度最高, 证明 MSM 描述性最强。

## 3. 提出一种高效且精确的匹配点对方法:

首先为 MSM 描述符建立  $k$  维树, 搜索描述符最接近的点初步建立匹配关系。在此基础上, 对点的三个几何信息提出算法约束, 第一次剔除错误匹配点对; 再使用刚性距离约束算法, 第二次剔除错误匹配点对。通过  $k$  维树初步建立匹配关系, 使后续配对时可以直接寻找对应的点, 其替代了传统方法中需要遍历全部点过程, 提高了效率, 同时又替代了设定欧氏距离阈值获取匹配点对的方式, 解决了因欧氏距离阈值不合理而导致删除正确匹配点对的问题; 后续又两次精炼匹配关系, 提高了获取匹配点对的正确率, 使粗配准的效果更好。